

République Algérienne Démocratique et Populaire
Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

École Nationale Polytechnique

Génie Industriel — Option DSIA



المدرسة الوطنية المتعددة التقنيات
Ecole Nationale Polytechnique

Projet de fin de semestre

Marketing Analytics Pipeline

Module :

Big Data, Data Mining et BI

Par :

Bouchama Nourane

2DSIA

Année scolaire 2025/2026

Table des matières

1	Introduction Générale	1
1.1	Contexte et Motivation	1
1.2	Enjeux et Vision	1
1.3	Architecture Globale du Pipeline	1
2	Identification du Problème	2
2.1	Situation Avant le Projet	2
2.2	Analyse de l'Impact	3
2.3	Objectifs de la Solution	3
3	Sources de Données	4
3.1	Description des Jeux de Données	4
3.1.1	Synthetic E-Commerce Dataset	4
3.1.2	Social Media Advertising (Kaggle)	6
4	Traitement Big Data — Hadoop & Spark	7
4.1	Vue d'ensemble de l'Écosystème Apache	7
4.2	Chargement des Données dans HDFS	8
4.2.1	Principe du Stockage Distribué	8
4.2.2	Commandes d'Upload HDFS	8
4.3	Traitement MapReduce	8
4.3.1	Principe du Paradigme MapReduce	8
4.3.2	Exécution du Job MapReduce via Hadoop Streaming	9
4.3.3	Exemple de Résultat MapReduce	10
4.4	Traitement Data Mining avec Apache Spark	10
4.4.1	Rôle de Spark dans le Pipeline	10
4.4.2	Comparaison des Approches : Spark → SSMS vs SSMS → Spark	11
4.4.3	Analyse Avancée et Segmentation des Clients avec PySpark	11
5	Pipeline ETL avec SSIS	14
5.1	Présentation de SSIS	14

5.2	Structure du Data Flow	14
5.3	Construction des Dimensions	15
5.3.1	Transformations Appliquées	15
5.3.2	Merge joint et Sort	16
5.3.3	Derived Column	17
5.4	Construction de la Table de Faits	17
5.4.1	Conception de <code>fact_marketing_operations</code>	17
5.4.2	Requête SQL de Creation	18
5.4.3	Requête SQL d'insertion	20
6	Entrepôt de Données — Star Schema (SSMS)	22
6.1	Architecture en Schéma en Étoile	22
7	Cube OLAP — SQL Server Analysis Services (SSAS)	23
7.1	Introduction à SSAS Multidimensionnel	23
7.2	Étape 1 — Création de la Data Source View (DSV)	23
7.2.1	Tables Inclues dans la DSV Marketing1	24
7.3	Étape 2 — Architecture du Cube	25
7.3.1	Groupe de Mesures	25
7.3.2	Dimensions du Cube	27
7.4	Étape 3 — Mesures Calculées (MDX)	27
7.4.1	Formules Mathématiques des KPI	28
7.5	Étape 4 — Indicateurs de Performance Clés (KPI)	29
7.6	Traitement du Cube	29
7.7	Optimisations SQL et Corrections de Types	30
7.7.1	Problème : Types de Données Incorrects dans les Vues	30
7.7.2	Solution : Vues SQL Optimisées avec Double Conversion	31
8	Dashboards Power BI	36
8.1	Connexion via Live Connect	36
8.2	Dashboard Commercial (Sales Performance)	37
8.2.1	Visuels Inclus	38
8.2.2	Insights Clés du Dashboard Sales	38
8.3	Dashboard Marketing (Marketing Performance)	39
8.3.1	Visuels Inclus	39
8.3.2	Insights Clés du Dashboard Marketing	40
8.4	Dashboard Expérience Client (Customer Experience & Segmentation)	40
8.4.1	Visuels Inclus	41
8.4.2	Insights Clés du Dashboard Expérience Client	41

9 Conclusion et Perspectives	42
9.1 Bilan du Projet	42
9.2 Valeur Métier Apportée	42
9.3 Perspectives d'Amélioration	43
9.4 Conclusion Finale	43

1. Introduction Générale

1.1 Contexte et Motivation

Dans un environnement de marché **fortement numérisé**, les entreprises modernes génèrent des volumes massifs de données à travers leurs campagnes publicitaires et leurs canaux de vente. La *Business Intelligence* (BI) contemporaine fait face à un défi central : **briser les silos entre données marketing et données commerciales** pour permettre une prise de décision éclairée et rapide.

Objectif Principal du Projet

Mettre en place une **architecture de données de bout en bout**, allant du stockage de données brutes non structurées (Big Data) jusqu'à la création de tableaux de bord interactifs Power BI, en passant par un entrepôt de données structuré en étoile et un cube OLAP multidimensionnel.

1.2 Enjeux et Vision

Ce projet répond à une vision décisionnelle en quatre axes :

1. **Consolidation** : Unifier les données dispersées entre marketing et ventes.
2. **Qualité** : Nettoyer et transformer des données brutes hétérogènes.
3. **Performance** : Accélérer les requêtes analytiques grâce à l'OLAP.
4. **Accessibilité** : Rendre l'analyse accessible aux décideurs via Power BI.

1.3 Architecture Globale du Pipeline

La figure ci-dessous illustre l'architecture complète de la solution mise en place.




FIGURE 1.1 – Architecture complète du pipeline de données marketing

2. Identification du Problème

2.1 Situation Avant le Projet

Avant la mise en place de cette solution, l'entreprise faisait face à des obstacles opérationnels et analytiques qui paralysaient toute tentative de pilotage data-driven.

Problèmes Critiques Identifiés

1. **Silos de données** : Les données marketing (réseaux sociaux : Facebook, Instagram, Pinterest, Twitter) et les données de ventes (système transactionnel) étaient stockées séparément.
2. **Données volumineuses et non structurées** : Les fichiers bruts présentaient des incohérences majeures : types textuels au lieu de numériques (ex : "20979.0" au lieu de 20979), décimales parasites ("2.50999..."), et valeurs manquantes (NULL).
3. **Lenteur analytique** : L'absence d'une structure multidimensionnelle (Cube OLAP) obligeait les analystes à exécuter des requêtes SQL lourdes directement sur les bases de production, pénalisant les performances globales.

2.2 Analyse de l'Impact

TABLE 2.1 – Matrice d'impact des problèmes avant la solution

Problème	Description	Impact	Priorité
Silos de données	Impossibilité de croiser marketing et ventes	Décisionnel bloqué	Critique
Qualité des données	Types incorrects, valeurs nulles, décimales parasites	Analyses faussées	Critique
Lenteur des requêtes	Requêtes SQL directement sur la production	Surcharge serveurs	Haute
Absence de KPI	Aucun indicateur de performance défini	Pilotage aveugle	Haute

2.3 Objectifs de la Solution

Objectifs Visés

- ✓ Construire un pipeline ETL robuste, automatisé et reproductible.
- ✓ Nettoyer et unifier toutes les sources de données en une seule vérité.
- ✓ Créer un entrepôt de données en **schéma en étoile** optimisé.
- ✓ Modéliser un cube SSAS avec KPI et mesures calculées (CTR, AOV...).
- ✓ Produire des dashboards interactifs Power BI pour les décideurs.

3. Sources de Données

3.1 Description des Jeux de Données

Le projet s'appuie sur trois catégories de données complémentaires, issues de sources synthétiques représentatives d'un environnement e-commerce réel.

3.1.1 Synthetic E-Commerce Dataset

Le jeu de données utilisé provient de la plateforme Kaggle et simule l'activité d'une plateforme de commerce en ligne. Contrairement à une table unique, ce dataset possède une structure relationnelle et se compose de cinq fichiers distincts au format CSV. Chaque fichier regroupe des informations spécifiques permettant de suivre le parcours d'achat, du profil de l'utilisateur jusqu'aux avis laissés sur les produits.

Description des fichiers du Dataset

1. Fichier `users.csv` : Ce fichier contient les informations de profil des clients inscrits sur la plateforme (nom, genre, localisation et date d'inscription).

TABLE 3.1 – Structure du fichier `users.csv`

Champ	Description	Type
<code>user_id</code>	Identifiant unique de l'utilisateur	VARCHAR
<code>name</code>	Nom complet de l'utilisateur	VARCHAR
<code>email</code>	Adresse électronique	VARCHAR
<code>gender</code>	Genre de l'utilisateur (Male, Female, Other)	VARCHAR
<code>city</code>	Ville de résidence	VARCHAR
<code>signup_date</code>	Date d'inscription sur la plateforme	DATE

2. Fichier `products.csv` : Il centralise le catalogue des produits disponibles à la vente avec leurs caractéristiques principales.

TABLE 3.2 – Structure du fichier `products.csv`

Champ	Description	Type
<code>product_id</code>	Identifiant unique du produit	VARCHAR
<code>product_name</code>	Nom commercial du produit	VARCHAR
<code>category</code>	Catégorie du produit (Electronics, Clothing, etc.)	VARCHAR
<code>brand</code>	Marque du produit	VARCHAR
<code>price</code>	Prix unitaire du produit	DECIMAL
<code>rating</code>	Note moyenne globale du produit	FLOAT

3. Fichier `orders.csv` : Il enregistre les transactions globales effectuées par les utilisateurs, permettant de suivre l'état de chaque commande.

TABLE 3.3 – Structure du fichier `orders.csv`

Champ	Description	Type
<code>order_id</code>	Identifiant unique de la commande	VARCHAR
<code>user_id</code>	Identifiant du client ayant passé la commande	VARCHAR
<code>order_date</code>	Date et heure de la commande	TIMESTAMP
<code>order_status</code>	Statut actuel (completed, processing, cancelled, etc.)	VARCHAR
<code>total_amount</code>	Montant total de la commande	DECIMAL

4. Fichier `order_items.csv` : Ce fichier fait le lien entre les commandes et les produits. Il détaille chaque article présent au sein d'une commande (table de jointure).

TABLE 3.4 – Structure du fichier `order_items.csv`

Champ	Description	Type
<code>order_item_id</code>	Identifiant unique de la ligne de commande	VARCHAR
<code>order_id</code>	Identifiant de la commande associée	VARCHAR
<code>product_id</code>	Référence du produit commandé	VARCHAR
<code>user_id</code>	Identifiant du client	VARCHAR
<code>quantity</code>	Quantité commandée pour ce produit	INT
<code>item_price</code>	Prix unitaire du produit au moment de l'achat	DECIMAL
<code>item_total</code>	Montant total pour cette ligne (Prix × Quantité)	DECIMAL

5. Fichier `reviews.csv` : Il recueille les évaluations et commentaires rédigés par les clients à la suite de la réception de leurs articles.

TABLE 3.5 – Structure du fichier reviews.csv

Champ	Description	Type
review_id	Identifiant unique de l’avis	VARCHAR
order_id	Identifiant de la commande concernée	VARCHAR
product_id	Référence du produit évalué	VARCHAR
user_id	Identifiant de l’auteur de l’avis	VARCHAR
rating	Note attribuée par le client (1 à 5)	INT
review_text	Commentaire textuel laissé par le client	TEXT
review_date	Date et heure du dépôt de l’avis	TIMESTAMP

3.1.2 Social Media Advertising (Kaggle)

Performances des campagnes sur quatre canaux digitaux :

TABLE 3.6 – Structure des données marketing (Social Media Advertising Dataset)

Champ	Description	Type
Campaign_ID	Identifiant de la campagne	VARCHAR
Channel	Plateforme (Facebook, Instagram...)	VARCHAR
Age_Group	Groupe d’âge ciblé	VARCHAR
Duration	Durée de la campagne	VARCHAR
Total_Impressions	Nombre total d’impressions	FLOAT*
Total_Engagement	Nombre total d’engagements	FLOAT*
Total_Clicks	Nombre total de clics	FLOAT*

4. Traitement Big Data — Hadoop & Spark

4.1 Vue d'ensemble de l'Écosystème Apache

Pour simuler un environnement Big Data capable de digérer de grands volumes de fichiers logs et données brutes, nous avons intégré l'écosystème Apache composé de HDFS, MapReduce et Spark (PySpark).




FIGURE 4.1 – Architecture en couches du système d'information décisionnel

4.2 Chargement des Données dans HDFS

4.2.1 Principe du Stockage Distribué

Le système de fichiers distribué HDFS (*Hadoop Distributed File System*) constitue la couche de stockage fondamentale. Il garantit :

- La **tolérance aux pannes** via la réplication des blocs (facteur de réplication configuré à 1 en environnement local de développement).
- La **scalabilité horizontale** pour absorber des volumes croissants.
- Le **traitement parallèle distribué** en rapprochant le calcul des données.

4.2.2 Commandes d'Upload HDFS

Script Bash — Initialisation HDFS et Upload des Données

```
# 1. Creation du repertoire de projet dans HDFS
hadoop fs -mkdir -p /marketing_project

# 2. chargement du dossier contenant les fichiers de donnees
hadoop fs -put \
    /mnt/c/Digital_Marketing \
    /marketing_project/

# 3. Verification du contenu du repertoire HDFS
hadoop fs -ls /marketing_project/
```

4.3 Traitement MapReduce

4.3.1 Principe du Paradigme MapReduce

MapReduce est le paradigme de traitement distribué fondamental d'Hadoop. Il opère en deux phases distinctes sur les données stockées en HDFS :

TABLE 4.1 – Phases du traitement MapReduce appliquées aux scripts

Phase	Rôle dans l'architecture	Application dans notre script
Map	Extraction, nettoyage et émission de paires clé-valeur textuelles.	extrait comme clé l'identifiant de la campagne et associe d'après les datasets le groupe d'âge , durée , produit ..etc
Shuffle & Sort	Regroupement et tri automatique de toutes les valeurs par clé unique	rassemble toutes les lignes de la campagne pour les envoyer vers le même Reducer.
Reduce	Désérialisation des valeurs, sommation des métriques et formatage final.	sépare la chaîne via les , additionne les impressions, engagements et clics , puis exporte la ligne au format CSV.

4.3.2 Exécution du Job MapReduce via Hadoop Streaming

Script Bash — Job MapReduce Hadoop Streaming


```
# Test local du pipeline Map -> Sort -> Reduce
cd /mnt/c/Digital_Marketing
cat Social_Media_Advertising.csv \
| python3 Map.py \
| sort \
| python3 Reduce.py > test_output.csv

# Execution distribuee via Hadoop Streaming
hadoop jar \
$HADOOP_HOME/share/hadoop/tools/lib/hadoop-streaming-*.jar \
-files Map.py,Reduce.py,products.csv \
-mapper "python3 Map.py" \
-reducer "python3 Reduce.py" \
-input /marketing_project/Social_Media_Advertising.csv \
-output /marketing_project/output_results

# Verification des resultats (20 premieres lignes)
hadoop fs -cat /marketing_project/output_results/part-00000 \
| head -n 20
```


4.3.3 Exemple de Résultat MapReduce

Un extrait de la sortie `part-00000` montre les données filtrées et agrégées, prêtes pour l'ingestion dans Spark :



Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	noran	supergroup	0 B	May 11 10:05	1	128 MB	_SUCCESS
-rw-r--r--	noran	supergroup	15.81 MB	May 11 10:05	1	128 MB	part-00000

FIGURE 4.2 – Sortie MapReduce



Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	noran	supergroup	2.81 KB	May 11 09:49	1	128 MB	Map.py
-rw-r--r--	noran	supergroup	1.37 KB	May 11 09:49	1	128 MB	Reduce.py
-rw-r--r--	noran	supergroup	39.02 MB	May 11 09:49	1	128 MB	Social_Media_Advertising.csv
-rw-r--r--	noran	supergroup	4.47 MB	May 11 09:49	1	128 MB	events.csv
-rw-r--r--	noran	supergroup	90.46 MB	May 11 09:49	1	128 MB	online_retail_II.csv
-rw-r--r--	noran	supergroup	2.11 MB	May 11 09:49	1	128 MB	order_items.csv
-rw-r--r--	noran	supergroup	1.17 MB	May 11 09:49	1	128 MB	orders.csv
drwxr-xr-x	noran	supergroup	0 B	May 11 10:05	0	0 B	output_results
-rw-r--r--	noran	supergroup	96.25 KB	May 11 09:49	1	128 MB	products.csv
-rw-r--r--	noran	supergroup	1.34 MB	May 11 09:49	1	128 MB	reviews.csv
-rw-r--r--	noran	supergroup	2.27 KB	May 11 09:49	1	128 MB	spark_job.py
-rw-r--r--	noran	supergroup	15.55 MB	May 11 09:49	1	128 MB	test_output.csv
-rw-r--r--	noran	supergroup	732.94 KB	May 11 09:49	1	128 MB	users.csv

FIGURE 4.3 – les fichiers d'après notre Hadoop interface

4.4 Traitement Data Mining avec Apache Spark

4.4.1 Rôle de Spark dans le Pipeline

Apache Spark (via **PySpark**) est utilisé pour des analyses en mémoire plus avancées, inaccessibles au seul MapReduce. Spark prend en charge :

1. **Nettoyage avancé des données** : suppression des doublons, gestion des valeurs nulles, normalisation des types.
2. **Analyse Exploratoire (EDA)** : profiling statistique des distributions.
3. **Data Mining** : segmentation des clients par comportement d'achat (`persona_cluster`), calcul du sentiment moyen (`avg_sentiment`) et de la note moyenne (`avg_rating`).

4.4.2 Comparaison des Approches : Spark → SSMS vs SSMS → Spark

TABLE 4.2 – Comparaison des deux architectures possibles

Critère	Spark → SSMS (Pré-traitement)	SSMS → Spark (Post-traitement)
Vision Projet	Data Engineering avancé	Analyste/Business
Complexité	Élevée (ML dans le pipeline)	Modérée (ML séparé)
Performance	Rapide (large-scale)	Plus lent (mouvement de données)
Choix Retenu	✓ Sélectionné	Alternatif

L'approche **Spark → SSMS** a été retenue car elle déplace le maximum de traitement lourd vers le cluster distribué, réduisant la charge sur SQL Server et garantissant des données pré-qualifiées avant l'entrepôt.

4.4.3 Analyse Avancée et Segmentation des Clients avec PySpark

Contrairement au traitement de bas niveau MapReduce axé principalement sur des agrégations basiques, le script `spark_job.py` implémente un pipeline complet de traitement de données et de Machine Learning distribué (PySpark MLlib). Son objectif principal est de segmenter les clients (générer des *personas*) à partir de l'analyse textuelle de leurs avis et de leurs comportements d'achat.

Détails des phases clés du traitement

1. **Calcul du score de sentiment** : Le script définit une liste de mots positifs (ex : *excellent*, *amazing*) et négatifs (ex : *terrible*, *poor*). Pour chaque avis, il calcule un score brut équivalent à :

$$\text{Score} = \sum \text{Mots Positifs} - \sum \text{Mots Négatifs}$$

2. **La méthode du coude automatique (*Elbow Method*)** : Au lieu de fixer arbitrairement le nombre de segments clients (K), le script automatise la recherche. Il calcule la fonction de coût (`trainingCost`) pour différentes valeurs de K . Il

évalue ensuite le gain d'efficacité entre chaque étape ($K - 1$ et K) :

$$\text{Gain} = \text{Coût}_{K-1} - \text{Coût}_K$$

La valeur de K qui maximise cette amélioration (le point où l'ajout d'un cluster supplémentaire apporte le moins de précision relative) est automatiquement sélectionnée pour le modèle final.

3. **Optimisation des entrées/sorties avec `.coalesce(1)`** : Étant donné que Spark est un framework de calcul distribué, le jeu de données final est naturellement découpé en plusieurs blocs (partitions) sur le cluster. L'appel à la fonction `.coalesce(1)` force Spark à rassembler intelligemment toutes les données traitées sur un seul et unique nœud juste avant l'écriture, permettant de générer proprement un rapport au format CSV unifié au lieu de multiples fragments séparés.

Le tableau 4.3 détaille l'enchaînement des phases de ce traitement au sein de l'architecture Spark.

TABLE 4.3 – Étapes du traitement et de la modélisation avec PySpark

Étape / Composant	Rôle Technique dans Spark	Application Dédiée au Script
Analyse textuelle (UDF)	Extension des capacités de transformation via une <i>User Defined Function</i> personnalisée.	Parcours du texte de l'avis (<code>review_text</code>) pour calculer un score de sentiment (<code>sent_score</code>) selon la présence de mots positifs/négatifs.
Agrégation Métrique	Regroupement et réduction distribuée des données par entité.	Calcul par <code>user_id</code> de la note moyenne (<code>avg_rating</code>), du sentiment moyen (<code>avg_sentiment</code>) et du niveau d'activité (<code>review_activity</code>).
Vectorisation	Transformation des caractéristiques au format requis par Spark MLlib.	Regroupement des colonnes d'agrégation dans un vecteur unique standardisé appelé <code>features</code> via un <code>VectorAssembler</code> .
Recherche du K optimal	Optimisation automatique des hyperparamètres du modèle de clustering.	Entraînement itératif de $K = 2$ à $K = 6$ et calcul automatique du coût d'inertie afin de localiser le « coude » (<i>Elbow Method</i>).
Clustering & Sauvegarde	Segmentation finale et écriture optimisée et centralisée du résultat.	Application du modèle K-Means optimal, prédiction du cluster (<code>persona_cluster</code>), puis regroupement des partitions via <code>.coalesce(1)</code> pour exporter un fichier CSV unique.

5. Pipeline ETL avec SSIS

5.1 Présentation de SSIS

SQL Server Integration Services (SSIS) orchestre le processus ETL (*Extract, Transform, Load*) entre l'environnement Big Data et l'entrepôt de données SQL Server. SSIS offre une interface visuelle permettant de concevoir des flux complexes sans code SQL brut.

5.2 Structure du Data Flow

Le package SSIS est architecturé autour de *Control Flow Tasks* et de *Data Flow Tasks* organisés séquentiellement :

1. **Suppression préalable** (delete data if exist) : nettoyage des tables cibles avant rechargement pour éviter les doublons.
2. **Data Flow Task** : connexion aux sources, transformation en mémoire, chargement vers SQL Server.
3. **Fact Table Task** : consolidation finale de la table de faits.
4. **Inserting Data Task** : insertion des enregistrements validés.




FIGURE 5.1

5.3 Construction des Dimensions

5.3.1 Transformations Appliquées

Chaque dimension requiert une chaîne de transformations SSIS spécifique :

TABLE 5.1 – Flux de données et transformations SSIS par table de destination

Destination / Table	Flux de Transformations Appliqués	Composants SSIS Utilisés
dim_client	Jointure des données clients brutes avec le fichier de clustering issu de <code>spark_job.py</code> . Tri préalable obligatoire sur la clé pivot commune.	Flat File Source, Sort, Merge Join
dim_review	Séparation du flux d'avis bruts via un composant de duplication pour alimenter parallèlement les dimensions textuelles et temporelles.	Flat File Source, Multicast
dim_temps	Extraction et conversion des formats de dates des avis en attributs isolés (Mois, Jour, Année) pour l'analyse temporelle.	Multicast, Derived Column
dim_produit	Chargement direct et mapping des colonnes depuis le référentiel des produits (<code>products.csv</code>).	Flat File Source, OLE DB Destination
dim_marketing	Collecte des métriques calculées (impressions, clics, engagements) générées par l'agrégation finale du script <code>Reduce.py</code> .	Flat File Source, OLE DB Destination




FIGURE 5.2

5.3.2 Merge joint et Sort

pour la dimension de client , on a eu deux fichiers pour les données , fichiers user.csv et le résultat de spark (clusters) alors on a décidé d'extraire les données des deux , pour cela il fallait appliquer un **Sort** comme suit :




FIGURE 5.3 – configuration de sort




FIGURE 5.4 – la configuration de merge joint

5.3.3 Derived Column

Pour chaque dim client une date, trois colonnes temporelles sont dérivées :

5.4 Construction de la Table de Faits

5.4.1 Conception de fact_marketing_operations

La table de faits centrale `fact_marketing_operations` unifie toutes les dimensions en une seule vue analytique. Elle combine :

- Les **clés de substitution** (Foreign Keys) des dimensions.
- Les **métriques quantitatives** : clics, impressions, engagements, montants.
- Les **attributs textuels** : texte des avis, statut des commandes.




FIGURE 5.5

5.4.2 Requête SQL de Creation

SQL — Create fact_marketing_operations

```

1 CREATE TABLE [fact_marketing_operations] (
2     [user_id] VARCHAR(50),
3     [product_id] VARCHAR(50),
4     [Date] DATETIME,
5     [order_id] VARCHAR(50),
6     [review_id] VARCHAR(50),
7     [Campaign_ID] VARCHAR(50),
8
9     [clicks] INT,
10    [engagements] INT,
11    [impressions] INT,
12    [Duration] VARCHAR(50),
13    [campaign_platform] VARCHAR(50),
14    [total_amount] FLOAT,
15    [quantity] VARCHAR(50),
16    [order_status] VARCHAR(50),
17    [rating] INT,
18    [sentiment_score] INT,
19    [review_text] VARCHAR(MAX),
20

```

```

21  CONSTRAINT FK_Client FOREIGN KEY (user_id) REFERENCES dim_clie(
22      user_id),
23  CONSTRAINT FK_Produit FOREIGN KEY (product_id) REFERENCES
24      dim_produits(product_id),
25  CONSTRAINT FK_DATE FOREIGN KEY ([Date]) REFERENCES dim_time([
26      Date]),
27  CONSTRAINT FK_ORDER FOREIGN KEY (order_id) REFERENCES dim_orders
      (order_id),
      CONSTRAINT FK_REVIEW FOREIGN KEY (review_id) REFERENCES Dim_Rev
      (review_id),
      CONSTRAINT FK_COMPAGN FOREIGN KEY (Campaign_ID) REFERENCES
      dim_Camp(Campaign_ID)
  );

```




FIGURE 5.6 – les configuration de tache d'exécution SQL — Fact table

5.4.3 Requête SQL d'insertion

SQL — INSERT INTO fact_marketing_operations

```

1  INSERT INTO [fact_marketing_operations] (
2      [user_id],
3      [product_id],
4      [Date],
5      [order_id],
6      [review_id],
7      [Campaign_ID],
8      [clicks],
9      [engagements],
10     [impressions],
11     [Duration],
12     [campaign_platform],
13     [total_amount],
14     [quantity],
15     [order_status],
16     [rating],
17     [sentiment_score],
18     [review_text]
19 )
20 SELECT
21     oi.[user_id],
22     oi.[product_id],
23     t.[Date] AS [Date],
24     oi.[order_id],
25     r.[review_id],
26     c.[Campaign_ID],
27     TRY_CAST(c.[Total_Clicks] AS INT) AS [clicks],
28     TRY_CAST(c.[Total_Engagement] AS INT) AS [engagements],
29     TRY_CAST(c.[Total_Impressions] AS INT) AS [impressions],
30     c.[Duration] AS [Duration],
31     c.[Channel] AS [
32         campaign_platform],
33     TRY_CAST(oi.[total_amount] AS FLOAT) AS [total_amount],
34     oi.[quantity] AS [quantity],
35     oi.[order_status] AS [order_status],
36     r.[rating] AS [rating],
37     TRY_CAST(u.[avg_sentiment] AS INT) AS [sentiment_score]
38     ],
39     r.[review_text] AS [review_text]
40 FROM
41     [dim_orders] oi

```

```

41     INNER JOIN [dim_clie] u ON oi.[user_id] = u.[user_id]
42     LEFT JOIN [Dim_Rev] r ON oi.[order_id] = r.[order_id]
43                        AND oi.[user_id] = r.[user_id]
44     LEFT JOIN [dim_Camp] c ON c.[Product] = oi.[product_id]
45     LEFT JOIN [dim_time] t ON t.[Date] = TRY_CAST(u.[
      signup_date] AS DATE)
46
47 WHERE
48     oi.[order_id] IS NOT NULL
49 AND oi.[user_id] IS NOT NULL
50
51 AND NOT EXISTS (
52     SELECT 1
53     FROM [fact_marketing_operations] f
54     WHERE f.[order_id] = oi.[order_id]
55     AND f.[user_id] = oi.[user_id]
56 );

```




FIGURE 5.7 – les configuration de tâche d'exécution SQL — Inserting data

6. Entrepôt de Données — Star Schema (SSMS)

6.1 Architecture en Schéma en Étoile

L'entrepôt de données adopte un **schéma en étoile** (*Star Schema*), modèle optimal pour les requêtes décisionnelles car il minimise les jointures et maximise la lisibilité analytique.




FIGURE 6.1 – Resultas de SSMS après le traitemet


7. Cube OLAP — SQL Server Analysis Services (SSAS)

7.1 Introduction à SSAS Multidimensionnel

Pour offrir des performances de calcul instantanées sur de grands volumes de données, les données du schéma en étoile ont été modélisées dans un **cube SSAS en mode Multidimensionnel** déployé sur Visual Studio (SQL Server Data Tools).

7.2 Étape 1 — Création de la Data Source View (DSV)

La **Data Source View** constitue le pont entre la base relationnelle SSMS et l'environnement multidimensionnel du cube. Elle sélectionne et organise les tables à inclure dans le modèle OLAP.



7.2.1 Tables Inclues dans la DSV Marketing1




FIGURE 7.1




FIGURE 7.2







FIGURE 7.3

7.3 Étape 2 — Architecture du Cube

7.3.1 Groupe de Mesures





La table `fact_marketing_operations` constitue l'unique groupe de mesures du cube. Les mesures sélectionnées sont :

TABLE 7.1 – Mesures du cube SSAS

Mesure	Description	Agrégation
Clicks	Total des clics par campagne	SUM
Engagements	Total des engagements	SUM
Impressions	Total des impressions publicitaires	SUM
Total Amount	Chiffre d'affaires total	SUM
Rating	Note de satisfaction client	AVG
Sentiment Score	Score de sentiment des avis	AVG
Fact Marketing Operations Nombre	Comptage des transactions	COUNT

7.3.2 Dimensions du Cube

Six dimensions ont été créées, chacune liée à sa table source : **Dim Clie**, **Dim Produits**, **Dim Rev**, **Dim Time**, **Dim Orders**, et **Dim Camp**.

7.4 Étape 3 — Mesures Calculées (MDX)

Des mesures calculées enrichissent l'analyse sans alourdir la base de données :

MDX — Mesures Calculées dans le Cube SSAS

```


1  -- 1. CTR (Click-Through Rate)
2  -- Formule : Clicks / Impressions
3  [Measures].[Clicks] / [Measures].[Impressions]
4
5  -- 2. Engagement Rate
6  -- Formule : Engagements / Impressions
7  [Measures].[Engagements] / [Measures].[Impressions]
8
9  -- 3. AOV (Average Order Value = Panier Moyen)
10 -- Formule : Montant Total / Nombre de commandes
11 [Measures].[Total Amount] / [Measures].[Count]
12
13 -- 4. Revenue per Click
14 -- Formule : Montant Total / Nombre de clics
15 [Measures].[Total Amount] / [Measures].[Clicks]
16
17 -- 5. Engagement per Click
18 -- Formule : Engagements / Clicks
19 [Measures].[Engagements] / [Measures].[Clicks]
20

```

```

21 -- 6. RPM (Revenue per Mille impressions)
22 -- Formule : (Montant Total / Impressions) * 1000
23 ([Measures].[Total Amount] / [Measures].[Impressions]) * 1000
24
25 -- 7. Conversion Rate
26 -- Formule : Quantite vendue / Clics (ratio zero si pas de clics)
27 IIF([Measures].[Clicks] = 0, NULL,
28     [Measures].[Quantity] / [Measures].[Clicks])

```



7.4.1 Formules Mathématiques des KPI

$$\text{CTR} = \frac{\text{Total Clicks}}{\text{Total Impressions}} \quad (7.1)$$

$$\text{Engagement Rate} = \frac{\text{Total Engagements}}{\text{Total Impressions}} \quad (7.2)$$

$$\text{AOV} = \frac{\text{Total Amount}}{\text{Nombre de Commandes}} \quad (7.3)$$

$$\text{RPM} = \frac{\text{Total Amount}}{\text{Total Impressions}} \times 1000 \quad (7.4)$$


$$\text{Conversion Rate} = \frac{\text{Quantity Sold}}{\text{Total Clicks}} \quad (7.5)$$

7.5 Étape 4 — Indicateurs de Performance Clés (KPI)

Cinq KPI ont été configurés dans le cube SSAS pour comparer les performances réelles aux objectifs métiers :

TABLE 7.2 – KPI configurés dans le cube SSAS

KPI	Expression de Valeur	Objectif	Indicateur
CTR Performance	[Measures].[CTR]	0.025 (2.5%)	Jauge
Engagement Rate Performance	[Measures].[Engagement_Rate]	0.05 (5%)	Jauge
Revenue per Click Performance	[Measures].[Revenue_per_Click]	défini	Jauge
AOV Performance	[Measures].[AOV]	défini	Jauge
Total Revenue Performance	[Measures].[Total Amount]	10 000	Jauge





7.6 Traitement du Cube

Une fois le modèle consolidé dans Visual Studio, l'opération **Process Full** a été lancée. Cette étape :

1. Compile la structure du cube.
2. Calcule toutes les agrégations pré-définies.
3. Déploie le cube sur le serveur d'analyse local.

Le résultat de traitement montre la réussite de toutes les dimensions et du groupe de mesures : *Traitement Cube « Marketing » terminé — Statut : Traitement réussi.*



7.7 Optimisations SQL et Corrections de Types

7.7.1 Problème : Types de Données Incorrects dans les Vues

Lors de la modélisation SSAS, des erreurs de types ont causé des axes illisibles et des valeurs nulles dans les cubes. Les causes identifiées étaient :

- Valeurs textuelles parasites ("20979.0") à la place d'entiers purs.
- Notations décimales étendues ("2.50999...") pour les ratings.
- Colonnes stockées en NVARCHAR empêchant les agrégations numériques.

7.7.2 Solution : Vues SQL Optimisées avec Double Conversion

SQL — Vue v_Fact_Sales (avec ROUND et TRY_CAST)

```

1  USE Marketing;
2  GO
3
4  ALTER VIEW [dbo].[v_Fact_Sales] AS
5  SELECT DISTINCT
6      f.user_id,
7      p.product_id,
8      TRY_CAST(c.signup_date AS DATE)          AS [Date],
9      f.order_id,
10     f.review_id,
11     TRY_CAST(r.quantity AS INT)              AS quantity,
12     TRY_CAST(r.total_amount AS DECIMAL(18,2)) AS total_amount,
13     r.order_status,
14     -- Normalisation : arrondi a 1 decimale elimine les 2.50999...
15     ROUND(TRY_CAST(r.Rating AS FLOAT), 1)    AS Rating
16 FROM [dbo].[Dim_Rev]      f
17     INNER JOIN [dbo].[dim_produits] p ON f.[product_id] = p.[
18         product_id]
19     INNER JOIN [dbo].[dim_orders]   r ON f.[order_id]   = r.[
20         order_id]
21     INNER JOIN [dbo].[dim_clie]     c ON f.[user_id]    = c.[user_id
22         ]
23 WHERE f.order_id IS NOT NULL;
24 GO

```

SQL — Vue v_Fact_Marketing (Élimination des Décimales dans Total_Clicks)

```

1  USE Marketing;
2  GO
3
4  ALTER VIEW [dbo].[v_Fact_Marketing] AS
5  SELECT DISTINCT
6      f.Campaign_ID,
7      p.product_id,
8      f.Channel,
9      f.Duration,
10     -- Double conversion : extraction partie entiere avant '.'
11     -- Traitement de "20979.0" => 20979 (INT propre)
12     TRY_CAST(
13         LEFT(

```

```
14         SUBSTRING(f.Total_Clicks,
15                     PATINDEX('%[0-9]%', f.Total_Clicks),
16                     LEN(f.Total_Clicks)),
17         CHARINDEX('.',
18                     SUBSTRING(f.Total_Clicks,
19                                 PATINDEX('%[0-9]%', f.Total_Clicks),
20                                 LEN(f.Total_Clicks)) + '.') - 1
21     ) AS INT
22 ) AS Total_Clicks,
23 -- Colonnes avec conversion simple (FLOAT -> INT)
24 TRY_CAST(TRY_CAST(f.Total_Engagement AS FLOAT) AS INT) AS
    Total_Engagement,
25 TRY_CAST(TRY_CAST(f.Total_Impressions AS FLOAT) AS INT) AS
    Total_Impressions
26 FROM [dbo].[fact_marketing_op] f
27     INNER JOIN [dbo].[dim_produits] p ON f.[Product] = p.[
    product_name]
28 WHERE f.Campaign_ID IS NOT NULL;
29 GO
```

Cette approche a été retenue afin d'éviter une correction manuelle de toutes les valeurs directement dans les tables sources. Les conversions et les règles de nettoyage sont centralisées dans les vues SQL, ce qui permet de conserver les données brutes tout en fournissant à SSAS des champs propres, typés et directement exploitables.

Après la création des vues `v_Fact_Sales` et `v_Fact_Marketing`, celles-ci ont été ajoutées dans la **vue de source de données** du projet SSAS. Les relations avec les dimensions ont ensuite été redéfinies afin que le modèle s'appuie sur ces vues corrigées plutôt que sur les tables initiales contenant des incohérences de types.

Dans le cube, l'ancien groupe de mesures basé sur la table `marketing_operations` a été supprimé. De nouveaux groupes de mesures ont ensuite été créés à partir des vues nettoyées, ce qui permet d'obtenir des mesures cohérentes pour les ventes et le marketing sans modifier physiquement les données d'origine.




FIGURE 7.4 – Schéma de la vue de source de données après l'ajout des vues SQL corrigées




FIGURE 7.5 – Ajout d'un nouveau groupe de mesures dans le cube SSAS




FIGURE 7.6 – Sélection des vues nettoyées comme sources des groupes de mesures

Cette configuration a permis de ajuster le cube sans la cration d'un nouveau en sélectionnant les vues corrigées comme tables de faits (figure 7.7).




FIGURE 7.7 – Création du nouveau cube à partir des vues SQL corrigées

Les mesures calculées et les KPI n'ont pas été réinsérés immédiatement dans ce nouveau cube. Cette décision permet d'abord de valider la structure, les relations et les agrégations de base avant de réintroduire les indicateurs avancés.

Le modèle obtenu est plus fiable, car les agrégations reposent sur des colonnes numériques correctement typées et sur des dates converties au bon format.

Mois	CTR P...	Clicks	Reven...	CTR	CTR P...	CTR Pe...
1	0,025	159...	0,000...	1,6...	1,603...	1
10	0,025	159...	0,000...	1,6...	1,603...	1
11	0,025	159...	0,000...	1,6...	1,603...	1
12	0,025	159...	0,000...	1,6...	1,603...	1
2	0,025	159...	0,000...	1,6...	1,603...	1
3	0,025	159...	0,000...	1,6...	1,603...	1
4	0,025	159...	0,000...	1,6...	1,603...	1
5	0,025	159...	0,000...	1,6...	1,603...	1
6	0,025	159...	0,000...	1,6...	1,603...	1
7	0,025	159...	0,000...	1,6...	1,603...	1
8	0,025	159...	0,000...	1,6...	1,603...	1
9	0,025	159...	0,000...	1,6...	1,603...	1


FIGURE 7.8 – resultats de navigateur de SSAS après les modifications


8. Dashboards Power BI

8.1 Connexion via Live Connect


Le cube SSAS étant déployé, Power BI Desktop s'y connecte en mode **Live Connect** (**Connexion en direct**). Ce mode présente deux avantages majeurs :

- **Aucune importation** : les données restent dans SSAS, éliminant les surcharges mémoire dans Power BI.
- **Délégation du calcul** : toutes les agrégations sont traitées par le moteur OLAP de SSAS, garantissant des temps de réponse instantanés.





8.2 Dashboard Commercial (Sales Performance)



Ce tableau de bord suit les performances commerciales de l'entreprise sur la période 2024–2025.

8.2.1 Visuels Inclus

TABLE 8.1 – Composants du Dashboard Commercial


Visuel	Description	Axes
Barre horizontale	Chiffre d'affaires par nom de produit	Produit vs Total Amount
Histogramme temporel	Quantité vendue par année et par mois	Mois/Année vs Quantity
Jauge AOV	Panier moyen vs objectif (542.87 € / 1.90K)	AOV Performance
Nuage de points	Corrélation Montant total vs Quantité par Rating	Total Amount, Quantity, Rating

8.2.2 Insights Clés du Dashboard Sales

Résultats Observés — Dashboard Commercial

- Le **produit Willow Hospital** génère le chiffre d'affaires le plus élevé (~40K), suivi de *Willow Result* et *Neotech Guess*.
- L'AOV mesuré est de **556.50 €** (objectif : 542.87 €, max 1.11K€).
- La corrélation Rating/Quantité montre que les produits les mieux notés ($\text{Rating} \geq 4$) ne sont pas nécessairement les plus vendus en volume, suggérant l'influence du prix.

8.3 Dashboard Marketing (Marketing Performance)



Ce tableau de bord analyse l'efficacité des campagnes publicitaires multi-canaux.

8.3.1 Visuels Inclus

TABLE 8.2 – Composants du Dashboard Marketing


Visuel	Description	Axes	Type
Barre horizontale	Clics par nom de produit	Produit vs Clicks	
Donut	Répartition des engagements par canal (Channel)	Channel vs Engagements	
Camembert	Répartition des clics par groupe d'âge	Age Group vs Clicks	
Jauge CTR	CTR réel vs objectif	160.30% 0.03 (2.5%)	KPI
Jauge Engagement Rate	Taux d'engagement vs objectif 0.05	0.14%	KPI
Nuage de points	Clics vs Impressions par marque	Brand	

8.3.2 Insights Clés du Dashboard Marketing

Résultats Observés — Dashboard Marketing

- Le **CTR mesuré** est de **160.30%** par rapport à l'objectif de 0.03 (soit +312.15% au-dessus de la cible fixée).
- L'**Engagement Rate** est de **0.14%** (objectif 0.05 — soit -97.15%), indiquant un fort volume de vues mais une faible interaction.
- **Facebook** et **Instagram** capturent les plus grandes parts des engagements (~30.52% chacun), suivis d'Instagram (30.42%) et Twitter (8.57%).
- Le groupe d'âge **18–24** représente la plus grande part des clics (22.41%), suivi des 25–34 ans et 35–44 ans.

8.4 Dashboard Expérience Client (Customer Experience & Segmentation)



Ce tableau de bord est alimenté par les résultats du modèle de clustering K-Means de PySpark. Il permet d'analyser la satisfaction globale des clients à travers les scores de sentiment extraits de leurs avis textuels, leur fidélité et la répartition de nos différents profils de consommateurs (*personas*).

8.4.1 Visuels Inclus

TABLE 8.3 – Composants du Dashboard Analyse Client

Visuel	Description	Axes
Stacked Bar Chart	RPM par catégorie et persona cluster	Catégorie vs RPM (Clusters 0, 1, 2)
Barres groupées	Montant total par persona cluster, quantité et genre	Persona Cluster vs Total Amount (Genre + Quantity)
Pie Chart (Donut)	Répartition de l’Average Order Value (AOV) par persona cluster	Persona Cluster vs AOV

8.4.2 Insights Clés du Dashboard Expérience Client

Observations Clés — Dashboard Expérience Client

- **Domination du Cluster 1** : Représente **65–85%** du RPM dans presque toutes les catégories (Electronics, Clothing, Home & Kitchen en tête).
- **Cluster 2 performant** : AOV le plus élevé à **604,16 €** (+23% vs autres clusters) et contribution forte sur les achats en grande quantité.
- **Cluster 0** : Part minoritaire et corrélé à des notes basses et sentiments négatifs (point de friction majeur).
- **Comportement genre** : Cluster 1 domine chez les hommes et femmes ; Cluster 2 plus actif sur les gros paniers chez les femmes.

9. Conclusion et Perspectives

9.1 Bilan du Projet

Ce projet démontre la faisabilité et l'efficacité d'une **chaîne décisionnelle moderne et complète**. En partant de fichiers CSV bruts et hétérogènes, le pipeline mis en place a permis de :

1. **Ingérer** les données dans HDFS pour un traitement distribué robuste.
2. **Filtrer et agréger** via MapReduce pour réduire la volumétrie initiale.
3. **Enrichir et classifier** les segments clients grâce à PySpark (clusters comportementaux, scores de sentiment).
4. **Transformer et charger** de façon automatisée et idempotente via SSIS.
5. **Structurer** en un entrepôt en étoile optimisé pour le décisionnel.
6. **Accélérer** les calculs analytiques via un cube OLAP SSAS avec KPI.
7. **Visualiser** les insights en temps réel dans des dashboards Power BI.

9.2 Valeur Métier Apportée

TABLE 9.1 – Valeur métier apportée par la solution

Problème Initial	Solution Apportée		Résultat
Silos Marketing/Ventes	Fact	table unifiée	ROAS calculable (fact_marketing_operations)
Données sales	Vues SQL optimisées + TRY_CAST + ROUND		Données propres
Lenteur analytique	Cube SSAS + Live Connect Power BI		Temps réel
Absence de KPI	5 KPI SSAS + 7 mesures MDX calculées		Pilotage précis

9.3 Perspectives d'Amélioration

- **Machine Learning intégré** : Déployer des modèles de prédiction de churn ou de scoring client directement dans le pipeline Spark.
- **Temps réel (Streaming)** : Intégrer Apache Kafka pour l'ingestion en flux des événements marketing.
- **Publication Cloud** : Migrer le cube SSAS vers Azure Analysis Services et publier les rapports sur Power BI Service pour un accès multi-utilisateurs.
- **Automatisation** : Planifier les rafraîchissements SSIS via SQL Server Agent pour des mises à jour nocturnes automatiques.
- **Data Governance** : Implémenter un catalogue de données (Azure Purview) pour documenter et contrôler la qualité des données à la source.

9.4 Conclusion Finale

L'interactivité visuelle obtenue sous Power BI, alimentée par un cube SSAS performant et un entrepôt de données rigoureusement modélisé, **permet désormais aux décideurs marketing et commerciaux de piloter précisément leurs stratégies à partir d'une source de vérité unique et consolidée**. Ce projet illustre concrètement comment l'ingénierie de données moderne transforme des données brutes disjointes en avantage concurrentiel mesurable.

*« Les données brutes sont la matière première ;
l'ingénierie de données est le raffinement ;
la Business Intelligence est la valeur. »*